Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №4

Метод k-ближайших соседей

по дисциплине «Системы искусственного интеллекта»

Выполнили:
Якименко Владислав Игоревич, №16
Пахомов Игнат Александрович, №8
Группа P3313

Проверил:
Жданов Андрей Дмитриевич

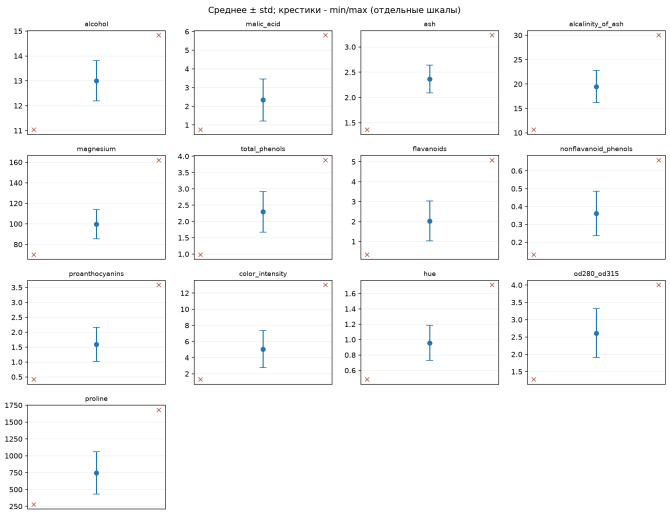
Санкт-Петербург
2026

1. Цель, данные и предварительная обработка

Цель работы - реализовать k-NN и сравнить результаты для двух наборов признаков при разных k. Используется датасет Wine из задания для чётного варианта. Он содержит 178 образцов вина, 13 числовых признаков и три класса: 59, 71 и 48 образцов. По химическим показателям нужно определить класс вина.

В исходных данных нет пропусков и категориальных признаков. В коде предусмотрены заполнение пропусков медианой и one-hot кодирование категорий. Данные разделены с сохранением долей классов: 142 объекта для обучения и 36 для проверки, seed=42. Для всех моделей разбиение одинаковое. Признаки стандартизированы по формуле z=(x-mean_train)/std_train. Средние, стандартные отклонения и медианы вычисляются только на обучающей части. Для масштабирования используется ddof=0, в таблице статистики - ddof=1.

Признак	count	mean	std	min	25%	50%	75%	max
alcohol	178	13.001	0.812	11.03	12.363	13.05	13.678	14.83
malic_acid	178	2.336	1.117	0.74	1.603	1.865	3.083	5.80
ash	178	2.367	0.274	1.36	2.21	2.36	2.558	3.23
alcalinity_of_ash	178	19.495	3.340	10.6	17.2	19.5	21.5	30.0
magnesium	178	99.742	14.282	70	88	98	107	162
total_phenols	178	2.295	0.626	0.98	1.743	2.355	2.80	3.88
flavanoids	178	2.029	0.999	0.34	1.205	2.135	2.875	5.08
nonflavanoid_phenols	178	0.362	0.124	0.13	0.27	0.34	0.438	0.66
proanthocyanins	178	1.591	0.572	0.41	1.25	1.555	1.95	3.58
color_intensity	178	5.058	2.318	1.28	3.22	4.69	6.20	13.0
hue	178	0.957	0.229	0.48	0.783	0.965	1.12	1.71
od280_od315	178	2.612	0.710	1.27	1.938	2.78	3.17	4.0
proline	178	746.893	314.907	278	500.5	673.5	985	1680



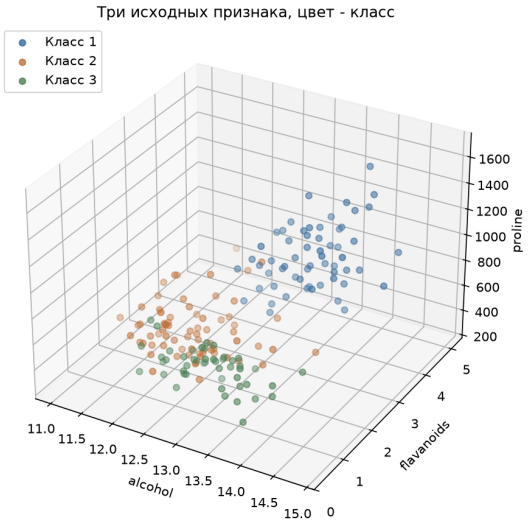
Описательная статистика: среднее, стандартное отклонение и крайние значения

2. Принцип работы и псевдокод

k-NN сохраняет обучающие объекты и их классы. Для нового объекта вычисляются расстояния до обучающих примеров, выбираются k ближайших и проводится голосование. Все соседи имеют одинаковый вес. Реализованы евклидово и манхэттенское расстояния. Для сортировки по евклидову расстоянию квадратный корень не нужен, поэтому используется сумма квадратов разностей. При равных расстояниях сохраняется порядок обучающих строк, при равном числе голосов выбирается меньшая метка класса.

Сохранить обучающие объекты и их классы.
Для каждого нового объекта:
  Вычислить расстояние до каждого обучающего объекта.
  Упорядочить расстояния по возрастанию.
  Взять первые k объектов.
  Подсчитать голоса по классам.
  Вернуть класс с максимальным числом голосов.
  При ничьей применить фиксированное правило.

Первая модель использует пять случайных признаков, выбранных без повторений с seed=42: nonflavanoid_phenols, total_phenols, hue, alcohol, proline. Для второй заранее выбраны alcohol, malic_acid, flavanoids, color_intensity, proline. В этот набор входят показатели содержания спирта, кислотности, флавоноидов, интенсивности цвета и пролина. В обеих моделях по пять признаков.



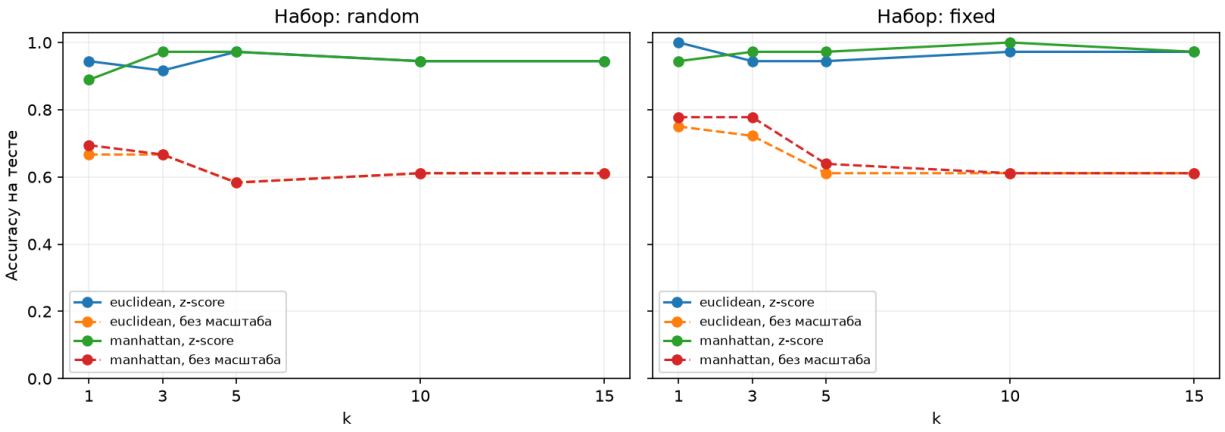
3D-визуализация: alcohol, flavanoids, proline; цвет обозначает класс

На 3D-графике показаны alcohol, flavanoids и proline. Цвет точки обозначает класс вина. Группы частично разделяются уже по этим трём признакам.

3. Эксперименты и результаты

Обе модели проверены при k=1, 3, 5, 10, 15. Дополнительно сравниваются два расстояния и варианты с масштабированием и без него. Всего получилось 40 комбинаций. В таблице приведены результаты после Z-score с евклидовым расстоянием. Accuracy - доля верных ответов; Precision, Recall и F1 усредняются по трём классам. Метрики и матрицы ошибок рассчитаны собственными функциями.

Набор	k	Accuracy	Precision macro	Recall macro	F1 macro
random	1	0.9444	0.9444	0.9524	0.9441
random	3	0.9167	0.9188	0.9286	0.9164
random	5	0.9722	0.9697	0.9762	0.9718
random	10	0.9444	0.9441	0.9524	0.9452
random	15	0.9444	0.9441	0.9524	0.9452
fixed	1	1.0000	1.0000	1.0000	1.0000
fixed	3	0.9444	0.9444	0.9524	0.9441
fixed	5	0.9444	0.9444	0.9524	0.9441
fixed	10	0.9722	0.9697	0.9762	0.9718
fixed	15	0.9722	0.9697	0.9762	0.9718

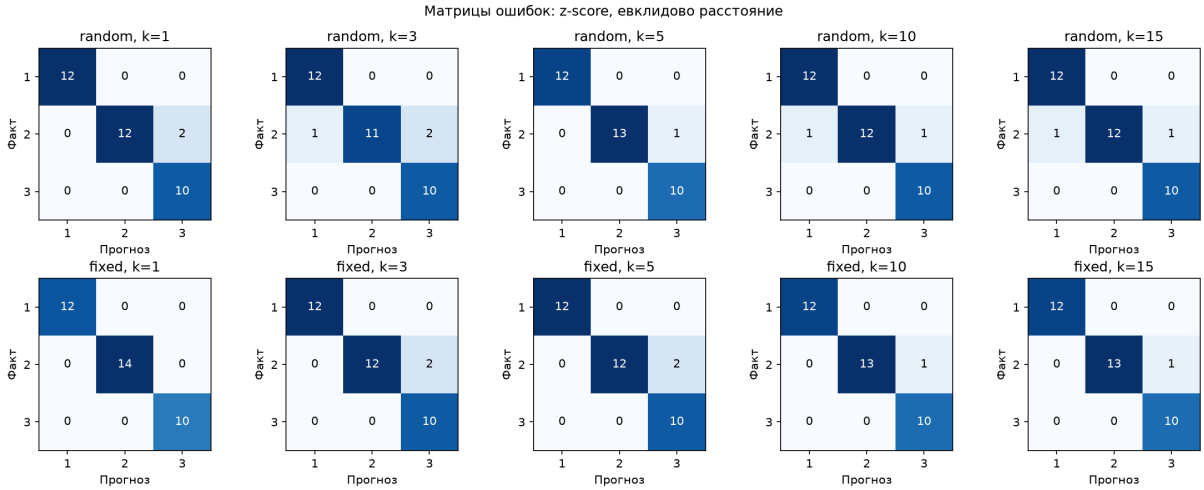


Accuracy в зависимости от k, расстояния и масштабирования

При k=5 масштабирование повысило Accuracy случайного набора с 0.5833 до 0.9722, фиксированного - с 0.6111 до 0.9444. Без него на расстояние сильно влияет proline: значения этого признака значительно больше остальных. Для манхэттенского расстояния фиксированный набор после Z-score дал Accuracy=1.0000 при k=10.

Результаты зависят от k и выбранных признаков. Тестовая часть небольшая: одна ошибка изменяет Accuracy примерно на 2.78 процентного пункта. В этой работе сравниваются заданные варианты на одном test; для более надёжного выбора k можно использовать кросс-валидацию на обучающих данных.

4. Матрицы ошибок и выводы



Матрицы ошибок для двух наборов и пяти значений k

Строки матриц соответствуют истинным классам, столбцы - предсказанным. На диагонали находятся верные ответы. В каждой матрице учтены все 36 тестовых объектов. Здесь показаны результаты двух моделей при пяти значениях k, после Z-score с евклидовым расстоянием. Остальные матрицы сохранены в CSV, гистограммы признаков - в results/figures/01_histograms.png.

Для фиксированного набора при k=1 получены 36 верных ответов из 36. Случайный набор при k=5 дал 35 верных ответов. По сравнению с изменением k масштабирование повлияло на результат сильнее. Результат 100% относится только к этой небольшой тестовой части; для оценки устойчивости нужны другие разбиения.

k-NN можно применять для определения типа продукта по измерениям или поиска похожих объектов. Метод прост, но требует хранить обучающие данные и вычислять расстояния при каждом прогнозе. В данной реализации сложность одного прогноза составляет O(Nd + N log N), память для обучающих данных - O(Nd). Метод чувствителен к масштабу признаков, шуму и большому числу измерений.

Реализация выполнена на Python с NumPy и Pandas, для графиков использован Matplotlib. Тестами проверены поиск соседей, голосование, равенство голосов, расстояния и предобработка. Параметры запуска и индексы выборок сохранены в results/experiment.json.

В работе использовался OpenAI Codex (ChatGPT). Результаты проверены запуском программы и тестов.