Федеральное государственное автономное образовательное учреждение высшего образования
«Национальный исследовательский университет ИТМО»

Факультет программной инженерии и компьютерной техники

Лабораторная работа №5

Деревья решений

по дисциплине «Системы искусственного интеллекта»

Выполнили:
Якименко Владислав Игоревич, №16
Пахомов Игнат Александрович, №8
Группа P3313

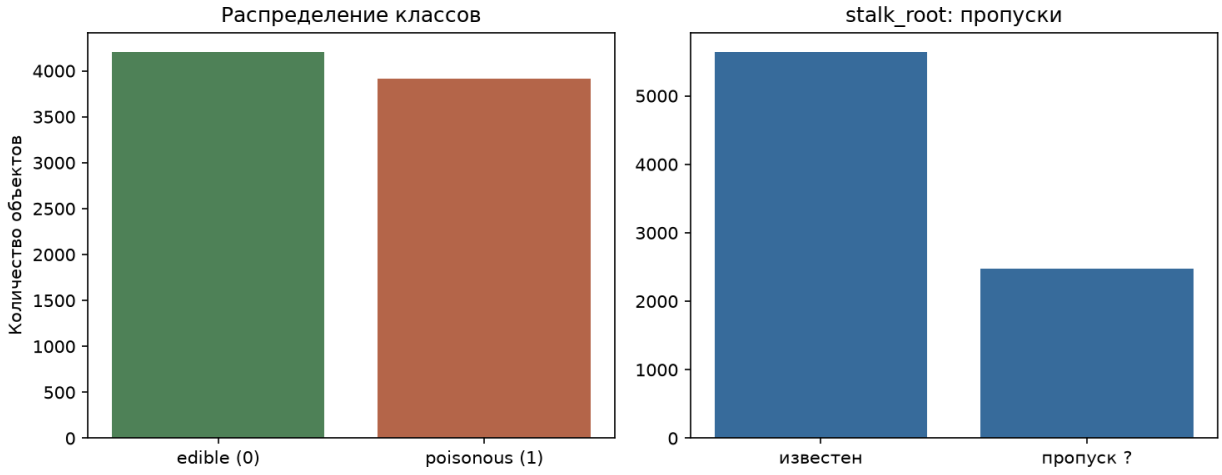
Проверил:
Жданов Андрей Дмитриевич

Санкт-Петербург
2026

1. Цель, данные и организация эксперимента

Цель работы - построить небинарное дерево решений для классификации грибов и оценить его качество. Для чётного варианта используется Mushroom: 8124 объекта и 22 категориальных признака. Положительный класс - poisonous=1, ядовитые грибы (3916 объектов); отрицательный - edible=0, съедобные (4208 объектов).

В столбце stalk_root есть 2480 пропусков, обозначенных '?'. В программе они заменяются на отдельную категорию __MISSING__. Остальные значения остаются строками. Дерево проверяет равенство категорий, поэтому масштабирование и числовое кодирование здесь не нужны. Для каждого признака сохранены частоты значений и количество пропусков.



Состав классов и количество пропусков в stalk_root

По условию выбраны четыре случайных признака: floor(sqrt(22))=4. При seed=42 получились stalk_shape, cap_surface, stalk_color_above_ring, veil_type. Выбор выполняется без повторений один раз для всего дерева. veil_type постоянный и не используется для разбиений. stalk_root с пропусками в выбранный набор не вошёл; обработка пропусков проверена отдельным тестом.

Данные разделены с сохранением долей классов: train=6499, test=1625, seed=42. Из train выделены 4874 объекта для построения пробных деревьев и 1625 для validation, seed=43. На validation сравниваются глубины 1, 2 и 4 по F1. При равенстве выбирается больший Recall, затем меньшая глубина. Итоговое дерево обучается на всём train и проверяется на test.

2. Метод и псевдокод

Реализован алгоритм ID3. В каждом узле выбирается признак, который сильнее всего уменьшает энтропию. Энтропия рассчитывается как H=-sum(p_c * log2(p_c)), где p_c - доля класса в узле. Для одного класса H=0, для двух классов в равных долях H=1 бит. Прирост информации равен IG=H(родителя)-sum((N_v/N)*H(ветви_v)). В этой формуле N_v - число объектов в ветви, N - число объектов в родительском узле.

Для каждого значения выбранного признака создаётся отдельная ветвь. Поэтому дерево небинарное, хотя классов всего два. Узел хранится в объекте Node, его потомки - в словаре children. Списки списков для хранения дерева не используются. После обучения структура сохраняется в JSON.

```
Создать узел с числом примеров и долей положительного класса.
Если класс чистый, нет признаков или достигнута глубина:
    Вернуть лист.
Для каждого доступного признака:
    Разбить примеры по всем значениям признака.
    Вычислить взвешенную энтропию потомков и прирост информации.
Если положительного прироста нет:
    Вернуть лист.
Выбрать признак с максимальным приростом.
Для каждого его значения:
    Рекурсивно построить потомка без использованного признака.
Вернуть узел со словарём потомков.
```

При прогнозе объект проходит по ветвям от корня до листа. Оценка P(poisonous) равна доле ядовитых обучающих объектов в листе. Если встретилась неизвестная категория, используется оценка текущего узла. При P>=0.5 выбирается класс poisonous. Оценки также используются для построения ROC и PR.

Accuracy=(TP+TN)/N; Precision=TP/(TP+FP); Recall=TP/(TP+FN). Положительный класс во всех формулах - poisonous. При нулевом знаменателе Precision/Recall принимаются равными нулю. ROC показывает TPR=Recall против FPR=FP/(FP+TN). PR показывает Precision против Recall.

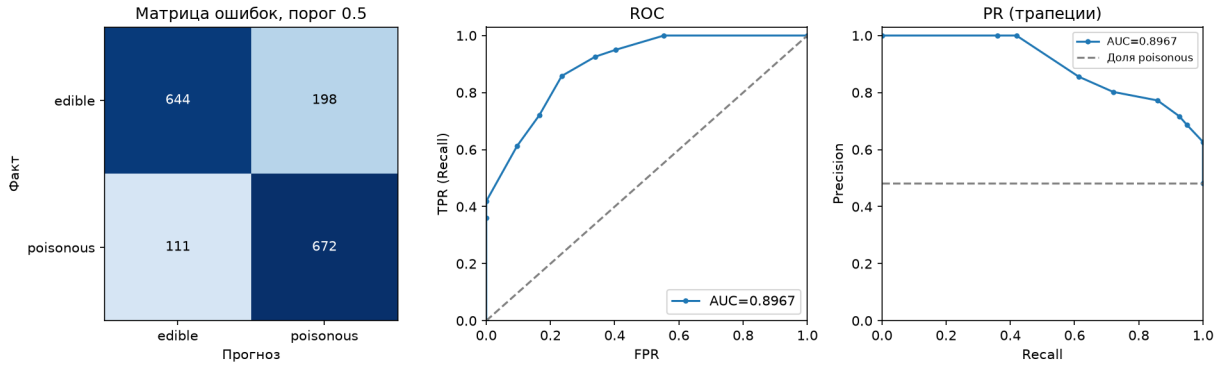
Для ROC и PR оценки сортируются по убыванию, одинаковые значения обрабатываются одной группой. Начальная точка ROC - (0,0), PR - (0,1): при отсутствии положительных прогнозов условно принимается Precision=1. Площади рассчитываются суммой трапеций. Для PR используется именно трапецеидальная площадь, а не Average Precision. Дерево, метрики и кривые реализованы без готовых ML-функций.

3. Результаты и проверка качества

Максимальная глубина	Accuracy validation	Precision	Recall	F1
1	0.7348	0.8024	0.5964	0.6842
2	0.7477	0.7202	0.7791	0.7485
4	0.8129	0.7788	0.8544	0.8149

По F1 выбрано ограничение глубины 4. Фактическая глубина дерева равна 3: из четырёх выбранных признаков три непостоянных. Получилось 30 узлов и 21 лист. В корне проверяется stalk_color_above_ring, у него девять потомков. Прирост информации в корне - 0.255904 бита.

Выборка	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
train	0.8057	0.7667	0.8580	0.8098	0.8991	0.9013
test	0.8098	0.7724	0.8582	0.8131	0.8967	0.8967



Матрица ошибок, ROC и PR итоговой модели на test

Матрица ошибок: TN=644, FP=198, FN=111, TP=672. Из 783 ядовитых тестовых объектов обнаружены 672, пропущены 111; Recall=672/783=0.8582. Среди 870 объектов, названных ядовитыми, 672 действительно относятся к этому классу; Precision=672/870=0.7724. Всего верно классифицированы 1316 из 1625 объектов.

ROC-AUC равна 0.8967 и показывает качество ранжирования объектов. Accuracy=0.8098 относится к порогу 0.5. Значения на train и test близки. Для проверки устойчивости результата можно повторить эксперимент с другими разбиениями.

4. Разбор дерева и выводы



Обзор дерева: корень и первый уровень, отдельная ветвь для каждого значения

На схеме показаны корень и первый уровень. Полное дерево сохранено в results/tree.json, все пути - в results/tree_rules.txt. Например, stalk_color_above_ring=b приводит к листу с P(poisonous)=1 на train. Для других цветов дерево может дополнительно проверить cap_surface и stalk_shape.

Для ограничения сложности использованы максимальная глубина и условия остановки. Удаление уже построенных ветвей не выполнялось. Результат зависит от обучающих строк и выбранных признаков. В случайный набор не вошёл odor и другие возможные полезные признаки, поэтому полученные метрики относятся только к выбранной четвёрке.

Деревья можно использовать для классификации заявок и контроля качества, когда нужны понятные правила решения. В данной задаче особенно важны пропуски ядовитых грибов: таких ошибок 111. Поэтому использовать эту учебную модель для определения безопасности грибов нельзя.

Тестами проверены энтропия, несколько ветвей в узле, ограничение глубины, постоянный признак, пропуски и неизвестные категории. Метрики проверены на известной матрице ошибок, ROC и PR - на примерах с известным порядком оценок. Для хранения и обработки данных использованы NumPy и Pandas, для графиков - Matplotlib.

В результате построено небинарное дерево по четырём случайным признакам. На тесте получены Accuracy=0.8098, Recall=0.8582 и ROC-AUC=0.8967. Наибольшее ограничение этого эксперимента - небольшой случайный набор признаков, один из которых постоянный.

В работе использовался OpenAI Codex (ChatGPT). Результаты проверены запуском программы и тестов.